




Primers passos de la ciència de dades

CRISP-DM

- Procés estàndard per a la mineria de dades.
- Un dels models més famosos per guiar projectes de ciència de dades.
- Fonts:
 - <https://start.agilytic.com/crisp-dm>
 - <https://www.datascience-pm.com/crisp-dm-2/>







Comprensió del problema empresarial

- Indica clarament el problema que cal resoldre i per què.
- Determinar si le ML és l'enfocament correcte per resoldre un problema.
- Verifiquen si teniu o podeu obtenir les dades correctes.
- Definir el valor potencial del projecte.
- Identificar els riscos del projecte, incloent-hi les consideracions ètiques.
- Desenvolupar i comunicar un pla de projecte flexible i d'alt nivell.




Comprensió del problema empresarial

- <https://developers.google.com/machine-learning/problem-framing>



Comprensió del problema empresarial


- Per als exercicis d'aquest curs no us heu de preocupar per això.
- Però potser hauràs de **preocupar-te** pel teu **projecte final** !





Dades

- Si les **dades** subjacents són **errònies** o **de baixa qualitat** , el model, la predicció, la visualització o la conclusió resultant també seran de **baixa qualitat** .
- Això és... Garbage In, Garbage Out (GIGO).





Comprensió de les dades

1. Recopilar les dades inicials.
2. Descriure les dades.
3. Explorar les dades.
4. Verificar la qualitat de les dades.



Comprensió de les dades

1. Recopilar les dades inicials.
2. Descriure les dades.
3. Explorar les dades.
4. Verificar la qualitat de les dades.



Recollida de dades

- Problemes comuns durant la recollida de dades:
 - Errors ortogràfics de valors de cadena, com ara noms de lloc, espècie o marca.
 - Conversions d'unitats, unitats o tipus d'objecte incorrectes.
 - Valors que falten.
 - Classificacions errònies o etiquetatge incorrecte constant.



Biaixos de recollida de dades

- **Biaix de mostreig** : les dades no són representatives de la població que es vol estudiar/predir.
 - Per exemple, vols saber amb quina freqüència la gent fa exercici a la teva ciutat, i ho preguntes a la gent del gimnàs... Això no reflecteix tota la població!




Biaixos de recollida de dades

- **Biaix de supervivència** : només es consideren els "supervivents", ignorant els que van fracassar, van desaparèixer o van ser exclosos.
 - Voleu predir el rendiment futur de les empreses, així que incloeu a les vostres dades les empreses actuals amb les seves mètriques econòmiques. El problema amb això és que heu ignorat empreses que ja han desaparegut...

Biaixos de recollida de dades

- **Biaix de supervivència** : només es consideren els "supervivents", ignorant els que van fracassar, van desaparèixer o van ser exclosos.





Recopilació de dades

- Consideracions importants abans de començar a treballar amb dades:
 - **Qui** va recollir les dades.
 - **Com i quan** es van recollir les dades i en quines condicions.
 - La sensibilitat i l'estat dels instruments de mesura.
 - Quines fallades instrumentals i errors humans s'han pogut produir.



Trampes de dades

- <https://developers.google.com/machine-learning/guides/data-traps>



Comprensió de dades

1. Recopilar les dades inicials.
- 2. Descriure les dades.**
3. Explorar les dades.
4. Verificar la qualitat de les dades.



Descriviu les dades: primera inspecció

- Propietats superficials de les dades:
 - Comproveu les dimensions del conjunt de dades.
 - Mireu les columnes i els seus valors.
 - Quins tenen valors nuls? Quantes files estan afectades?
 - Comproveu els tipus de columna (int, float, etc.).
 - Converteix algunes columnes a un tipus específic (per exemple, int, datetime, etc.).



Descriviu les dades: primera inspecció

- Propietats superficials de les dades:
 - Comproveu les dimensions del conjunt de dades. → **Pandes: shape**
 - Mireu les columnes i els seus valors. → **Pandes: head, tail, description, info**
 - Quins tenen valors nuls? Quantes files estan afectades? → **Pandas: isna, info**
 - Comprova els tipus de columna (int, float, etc.). → **Pandas: dtypes, info**
 - Converteix algunes columnes a un tipus específic (per exemple, int, datetime, etc.).
→ **Pandas: astype, to_datetime**



Comprensió de les dades

1. Recopilar les dades inicials.
2. Descriure les dades.
- 3. Explorar les dades.**
4. Verificar la qualitat de les dades.



Anàlisi Exploratòria de Dades (EDA)



- Resumir les principals característiques de les dades amb visualitzacions.
- Tipus de gràfics essencials per a la visualització de dades:
 - <https://www.atlassian.com/data/charts/essential-chart-types-for-data-visualization>



Anàlisi Exploratòria de Dades (EDA)

- Algunes idees comunes:
 - Distributions de totes les característiques:
 - Histograma o diagrama de caixa per a característiques contínues.
 - P. ex., els valors de la mostra segueixen un patró específic?

Histograma i diagrama de caixa






Anàlisi Exploratòria de Dades (EDA)

- Algunes idees comunes:
 - Distribucions de totes les característiques:
 - Histograma o diagrama de caixa per a característiques contínues.
 - Diagrama de barres per a característiques categòriques.
 - Per exemple, les categories segueixen un patró específic?

Gràfic de barres






Anàlisi Exploratòria de Dades (EDA)

- Algunes idees comunes:
 - Distribucions de totes les característiques: histograma, diagrama de caixa/barres.
 - Matriu de correlació entre tots els parells de característiques.

Correlació Matriu





Anàlisi Exploratòria de Dades (EDA)

- Algunes idees comunes:
 - Distribucions de totes les característiques: histograma, diagrama de caixa/barres.
 - Matriu de correlació entre tots els parells de característiques.
 - Correlacions de les característiques amb l'objectiu.




Anàlisi Exploratòria de Dades (EDA)

- Algunes idees comunes:
 - Distribucions de totes les característiques: histograma, diagrama de caixa/barres.
 - Matriu de correlació entre tots els parells de característiques.
 - Correlacions de les característiques amb l'objectiu.
 - Gràfic de parelles. → Aneu amb compte! Pot ser molt lent si hi ha moltes dades.



Trama de parells





Anàlisi Exploratòria de Dades (EDA)

- Algunes idees comunes:
 - Distribucions de totes les característiques: histograma, diagrama de caixa/barres.
→ **Pandas: hist, boxplot, bar**
 - Matriu de correlació entre tots els parells de característiques.
→ **Pandas: corr ; Seaborn: heatmap**
 - Correlacions de les característiques amb l'objectiu. → **Pandas: corr.**
 - Gràfic de parells (pairplot). → **Pandas.plotting: scatter_matrix ; Seaborn: pairplot**



Comprensió de les dades

1. Recopilar les dades inicials.
2. Descriure les dades.
3. Explorar les dades.
4. **Verificar la qualitat de les dades.**



Verificar la qualitat de les dades

- Les dades són completes (cobreixen tots els casos requerits)?
- És correcte o conté errors? Com de freqüents són?
 - Hi ha files/columnes erròniament duplicades?
- Hi ha valors que falten a les dades?
 - Com estan representats? On es produeixen? Com de comuns són?



Comprensió de les dades

1. Recopilar les dades inicials.
2. Descriure les dades.
3. Explorar les dades.
4. Verificar la qualitat de les dades.

Cadascun d'aquests passos ha d'estar
clarament documentat i informat!



Comprensió de les dades

~~1. Recopilar les dades inicials.~~

- No és necessari pels exercicis (però sí que ho faràs pel **teu projecte**).

2. Descriure les dades.

3. Explorar les dades.

4. Verificar la qualitat de les dades.



Comprensió de les dades

- Per tenir una idea ràpida de tot el que hem parlat, podeu utilitzar:
 - Llibreria: `fg-data-profiling` (`pip install fg-data-profiling[notebook]`)

Etiqueta de l'alerta	Què significa realment	Quan s'activa (Valors per defecte)
High Correlation	Dues columnes “dupliquen la mateixa informació”.	El coeficient de Pearson o Spearman és alt.
Constant	La columna no aporta cap informació perquè totes les files tenen exactament el mateix valor.	Només hi ha 1 valor únic en tota la columna.
Zeros	La columna està plena de valors zero o actua com un indicador buit/mut (flag).	El valor 0 representa més del 50% de les files.
Missing Values	La columna conté registres buits, cel·les en blanc o valors NaN .	Qualsevol presència de valors nuls o buits.
High Cardinality	Una columna de text (categòrica) té masses valors diferents (com un ID d'usuari o noms propis).	La columna conté més de 50 valors de text diferents i únics.
Skewness	Les dades estan molt amuntegades en un costat en lloc d'una forma simètrica.	La puntuació d'asimetria és > 20.0 (un límit bastant agressiu).
Uniform	Les dades estan completament distribuïdes de manera plana i equivalent (com llançar un dau ideal).	La columna falla el test estadístic de Xi-quadrat.
Imbalance	Una categoria específica domina gairebé la totalitat de tot el conjunt de dades.	S'utilitza una mètrica d'entropia on una sola categoria eclipsa completament les altres.



Comprensió de les dades

1. Recopilar les dades inicials.
 2. Descriure les dades.
 3. Explorar les dades.
 4. Verificar la qualitat de les dades.
- Recomanació pel curs: fer tot aquest procés en un únic notebook.
 - En el món real, si les dades són complexes, potser estaria bé separar diferents processos en diferents notebooks i documents.