

Classification: Experiments Bonus

Aquestes idees d'exercicis són exploratòries i no segueixen cap ordre concret. Aprofundeix en les que et despertin més interès.

Treballa els exercicis següents fent servir el teu **hotel dataset** processat.

L'estrella (★) indica els que es consideren més rellevants.

★ Metrics

- A més de les mètriques habituals vistes a classe, assegura't que també entens el **F1 score**, la **sensitivity** i la **specificity**. Reconeix quan aquestes mètriques són especialment útils per avaluar el rendiment del teu model.

★ Decision threshold

- El decision threshold especifica a quina probabilitat la predicció és un 0 o és un 1.
- Per defecte, la majoria de models el fixen a 0.5.
- P. ex., les mostres amb una probabilitat de 0.45 (45%) de ser un 1 s'assignen a 0, i les features amb probabilitat de 0.55 (55%) de ser un 1 s'assignen a 1.
- Representa (plot) un gràfic on l'eix x sigui el decision threshold (entre 0 i 1) i l'eix y el rendiment del model (p. ex., representa precision i recall en línies diferents). Veuràs com varien les prediccions en canviar aquest threshold.

★ ROC-AUC

- Busca informació i entén què és la ROC curve i l'AUC score.
- Representa la ROC curve i mostra l'AUC score dels teus models.

★ Precision-Recall Curve

- Busca informació i entén què és la Precision-Recall curve.
- Representa-la per als teus models.

Diferents K per a Cross-validation

- Examina l'impacte d'utilitzar diversos valors de K en la cross-validation.
 - Visualitza les mètriques de rendiment d'un model triat amb diferents valors de K.
 - Representa tant els training com els validation scores.
 - Representa el temps de computació associat als diferents valors de K per a la cross-validation.

Learning Curves

- Fes experiments amb un o més dels teus millors models, entrenant-los amb diferents porcions de dades.
 - Per exemple, parteix el teu training set en 10% training i 90% validation sets (aquí no cal cross-validation). Obtens un bon rendiment?

- Analitza els resultats i visualitza'ls per a diferents porcions de dades com ara 10-90, 20-80, etcètera.

Dimensionality Reduction

- Aprèn sobre Principal Component Analysis (PCA). No cal entendre tots els detalls.
 - Representa un gràfic que mostri el rendiment del model en variar el nombre de principal components.
 - Extreu conclusions dels teus resultats.
- Selecciona les features més importants (p. ex., basant-te en les RF feature importances o els coeficients de Lasso) i torna a entrenar els teus millors models. Observa si hi ha canvis en el rendiment.
- Entén la Feature Recursive Elimination (RFE) i aplica-la. Anota qualsevol millora o empitjorament del rendiment.
- Aprèn sobre t-SNE i explora'l. Si el temps de computació es converteix en un problema, redueix la mida del teu dataset.
- De la mateixa manera, experimenta amb UMAP.

Tree-based Models

- Entén el concepte de l'estimació Out-of-bag (OOB). Comprova-la al teu model RF i compara els resultats amb els validation scores.
- Aprèn sobre Extratrees i aplica'l.
- Prova altres llibreries més adequades per als tree-based models que sklearn. P. ex., XGBoost, LightGBM o CatBoost.

Bagging

- Fes servir Bagging amb algorismes de ML diferents dels Decision Trees, com ara LR o kNN. Consulta BaggingRegressor a sklearn. Interpreta els resultats i teoritza per què s'han produït certs resultats. Pensa maneres de millorar el rendiment.

Boosting

- Fes servir Gradient Boosting amb algorismes diferents dels Decision Trees, com ara LR o kNN. Consulta GradientBoostingRegressor a sklearn. Interpreta els resultats i teoritza per què s'han produït certs resultats. Pensa maneres de millorar el rendiment.
- Aprèn sobre AdaBoost i aplica'l.

Altres tècniques d'Ensembling

- Aprèn sobre stacking i aplica'l.
- Aprèn sobre blending i aplica'l.
- Aprèn sobre cascading i aplica'l.

Interpretability

- Aprèn sobre Permutation Feature Importance i aplica-la per entendre la contribució de cada feature a la predicció. Consulta `permutation_importance()` a sklearn.

- De la mateixa manera, aprèn i experimenta amb SHAP (SHapley Additive exPlanations).
- De la mateixa manera, aprèn i experimenta amb LIME.

Hyperparameter Optimization

- Aprèn sobre la Bayesian optimization i aplica-la.

Més Features

- Deriva (a partir dels atributs existents) més features que puguin ser útils per a la predicció.
- Per què és útil transformar algunes features calculant-ne el logaritme? Investiga-ho, pensa-hi i prova-ho.
- Per què és útil transformar algunes features calculant-ne un polinomi? Investiga-ho, pensa-hi i prova-ho.

Automatic ML

- Explora l'automated machine learning fent servir llibreries com ara Auto-sklearn, H2O AutoML, Optuna, TPOT, entre d'altres.

Full Pipeline

- Imagina un sistema automatitzat de classification que rep noves dades periòdicament. Dissenya un pipeline complet per emular aquest procés: data preprocessing, train/test splitting, hyperparameter tuning, validation, testing i monitoring (incloent-hi logs d'avaluació del rendiment i possibles alertes de fallada).
- Model Drift Detection: implementa mecanismes per detectar si el rendiment del model es degrada amb el temps a mesura que es disposa de noves dades.