

Cross-Validation (CV) – Validació Creuada


Divisió Única Train / Test

- Problemes principals:
 - La divisió pot no representar la distribució general de les dades, donant lloc a avaluacions enganyoses.
 - Overfitting al conjunt de test: un bon rendiment en el test pot no generalitzar-se a altres dades.


K-fold cross-validation

- Una tècnica habitual és aplicar la **cross-validation** amb el conjunt de **train**:
 - Dividir les dades d'entrenament en k parts/*folds*.
 - Entrenar un model amb $(k - 1)$ parts.
 - Validar amb la part restant.
 - Repetir k vegades amb combinacions diferents de les parts.
 - Calcular la mitjana de les mètriques de rendiment.

K-fold cross-validation



Flux ML Complet



Resum

1. Netejar i preprocessar les dades.
2. Decidir quines **mètriques** s'adapten millor al problema, p. ex., **MAE** o **RMSE**.
3. Dividir les dades en conjunts de **train** i **test**.
4. Provar el rendiment de diferents models amb **CV**:
 - *Dummy*.
 - LR, etc.
 - Anar amb compte amb l'**overfitting** i l'**underfitting**.
5. Escollim els models més prometedors i els provem en el conjunt de test.
6. Conservar el millor model o tornar a un pas anterior si el rendiment no és bo.