




Data Leakage





Data Leakage

- Quan les dades s'utilitzen de manera inadequada i irrealista per entrenar els models.
- Dóna un avantatge injust al nostre model.
- Casos típics:
 - Dades no disponibles en producció.
 - Fuita d'objectiu.
 - Contaminació entrenament-validació-test.



Data Leakage – Característiques no disponibles

- Ús de dades externes que no estaran disponibles en producció.
- Exemples:
 - Utilitzant el PIB que es calcula després del moment dels nostres registres.
 - El mateix si s'utilitzen comunicats de notícies futures.
 - En predicció del preu de l'habitatge, usar indicadors econòmics calculats posteriors.



Data leakage del target

- Derivar característiques de la variable objectiu.
- Ajuda incorrectament el model a fer prediccions millors.
- Aquestes features no estaran disponibles a producció, ja que no coneixerem el target.
- Exemple de nova característica:
 - €/m² basat en el preu i m² de cada mostra d'habitatge.
 - Medicaments dels pacients que només es prescriuen després del diagnòstic.



Contaminació Train-Validation-Test

- Incloure informació dels conjunts de validació/test en les features de train.
- Els conjunts de dades de train i validació/test han d'estar correctament aïllats!
- Exemples quan s'utilitza tot el conjunt de dades:
 - Escalat de característiques.
 - Selecció de característiques.
 - Nova característica: €/m² a la zona (derivada de tot el conjunt de dades).



Contaminació Train-Validation-Test

- Com fer-ho correctament:
 - No realitzeu EDA ni altres estadístiques descriptives sobre les dades de prova.



Contaminació Train-Validation-Test

- Com fer-ho correctament:
 - No realitzeu EDA ni altres estadístiques descriptives sobre les dades de prova.
 - Utilitzeu només el conjunt de train per calcular les estadístiques del target.
 - És a dir, fins i tot en CV, no hauríem d'utilitzar dades de validació.
 - Per exemple, preu mitjà de les cases a la zona.