




Preparació de les dades





Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
4. Integrar dades.
5. Formatar dades.



Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
4. Integrar dades.
5. Formatar dades.



Seleccionar dades

- Quins conjunts de dades s'utilitzaran.



Preparació de les dades

1. Seleccionar dades.
- 2. Netejar dades.**
3. Construir dades.
4. Integrar dades.
5. Formatar dades.



Netejar dades

- Eliminar les característiques (columnes) innecessàries.



Netejar dades

- Eliminar les característiques (columnes) innecessàries.
- Tractar els valors nuls: Antigament recomanat eliminar/imputar. **Això ja no és cert!**
 - Corregeix-los només si tens clar el valor real que haurien de tenir.
 - Elimina tota la fila si conté molts nuls i estàs convençut que no conté informació rellevant.
 - Elimina tota la columna si conté molts nuls i estàs convençut que no conté info rellevant.
 - P. ex. columna és *tractament_cancer_alternatiu* i té 95% de nuls → **No l'eliminem!**



Netejar dades

- Eliminar les característiques (columnes) innecessàries.
- Tractar els valors nuls.
- Eliminar els duplicats si són errors.



Netejar dades

- Eliminar les característiques (columnes) innecessàries.
- Tractar els valors nuls.
- Eliminar els duplicats si són errors.
- Valors atípics:
 - Elimineu-los o imputeu-los si hi ha errors.
 - Decidir què fer si no són errors.



Netejar dades

- Eliminar les característiques (columnes) innecessàries.
- Tractar els valors nuls.
- Eliminar els duplicats si són errors.
- Valors atípics.
- Eliminar característiques altament correlacionades.
 - Si la correlació és del 100% (1 o -1) o proper, és interessant eliminar-les, alguns models treballaran millor.



Netejar dades

- Eliminar les característiques (columnes) innecessàries. → **Pandas: drop**
- Tractar els valors nuls: → **Pandas: isna, info**
- Eliminar els duplicats si són errors. → **Pandas: duplicated, drop_duplicates**
- Valors atípics. → **Pandas: drop**
- Eliminar característiques altament correlacionades. → **Pandas: drop**



Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. **Construir dades.**
4. Integrar dades.
5. Formatar dades.



Construir dades

- Derivar noves característiques (útils) a partir de les existents.
- Exemples:
 - Massa corporal a partir dels atributs d'alçada i pes.
 - Velocitat mitjana a partir de la distància i la durada.
 - Habitacions per m².
 - Preu mitjà per m² de vivendes a 1km a la rodona.



Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
- 4. Integrar dades.**
5. Formatar dades.



Integrar dades

- Combinar dades (útils) d'altres fonts.
- Exemples per a la predicció del preu de l'habitatge:
 - Ingressos mitjans al barri.
 - Distància a: escola, supermercat, autobús, metro, centre de la ciutat...



Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
4. Integrar dades.
5. **Formatar dades (també conegut com a “feature engineering”).**
 - **Ho veurem més endavant.**



Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
4. Integrar dades.
5. Formatar dades.

Cadascun d'aquests passos ha d'estar
clarament documentat i informat!



Preparació de les dades


~~1. Seleccionar dades.~~


2. Netejar dades.

3. Construir dades.

~~4. Integrar dades.~~

5. Formatar dades.

- 
- No et preocupis per això pels exercicis.
 - Però potser hauràs de **preocupar-te'n** pel teu **projecte final** !



Aquestes 3 parts són normalment les més llargues del flux de treball, però les que tenen més influència en les bones prediccions!



Preparació de les dades

1. Seleccionar dades.
 2. Netejar dades.
 3. Construir dades.
 4. Integrar dades.
 5. Formatar dades.
- Recomanació pel curs: fer tot aquest procés en un únic notebook.
 - En el món real, si les dades són complexes, potser estaria bé separar diferents processos en diferents notebooks i documents.