

Data Science Workflow

1. Business Problem Understanding:

- Alinea els objectius de data science amb els objectius de negoci per assegurar que la solució resol el problema correcte.

2. Data Collection:

- Recull dades rellevants de fonts diverses per obtenir un dataset complet que permeti una anàlisi precisa.

3. Exploratory Data Analysis (EDA):

- Fes una anàlisi estadística i visual a fons per entendre les dades i descobrir patrons, tendències i anomalies.

4. Data Cleaning and Processing:

- Tracta els valors nuls
- Filtra els outliers erronis
- Elimina duplicats
- Descarta features redundants
- Inventa features noves
- ...

5. Feature Engineering:

- Només necessari per a alguns algorismes de ML
- Codifica les features categòriques
- Imputa o elimina els valors nuls que quedin
- Feature Scaling: Escalar les features, requerit només per a algorismes sensibles a les distàncies, com els mètodes lineals o les xarxes neuronals.

6. Machine Learning (ML):

- **Train/Test Split**
- **Cross-validation:** Fes servir cross-validation sobre el train set per validar diferents models i hyperparameters. Recorda incloure un baseline per assegurar que els teus models el superen.
- **Model Selection:** Fes servir el rendiment de validation per triar uns quants models bons, i després confirma el seu rendiment sobre el test set.
- **Finalize Model Training:** Fins ara has entrenat només sobre el train set, perquè necessitaves el test set (dades mai vistes) per mesurar el rendiment de manera honesta. Un cop ja has triat el model i els hyperparameters definitius, el test set ja ha complert la seva funció. Arribats aquí tens dues opcions:
 - **Tornar a entrenar sobre tot el dataset** (train + test juntes), per aprofitar tota la informació disponible abans de posar el model a producció. El preu que pagues és que aquest model final ja no es pot avaluar: no et queden dades no vistes per comprovar-ne el rendiment.

- **Quedar-te amb el model entrenat només sobre el train set**, que també és una opció perfectament vàlida: ja ha demostrat que funciona bé sobre el test set (dades mai vistes), així que tens una estimació fiable del seu rendiment real.
- **Model Storage**: Desa el model per a usos futurs.

7. Desplegament a producció:

- Desplega el model desat en un entorn real, monitoritza el seu rendiment i mantén-lo per garantir-ne la precisió i la fiabilitat.

Nota: Si un pas del procés no dóna els resultats esperats, revisa els passos anteriors per fer-hi possibles ajustaments. Per exemple, si el model de machine learning no funciona bé, pot ser necessari recollir més dades o dades diferents per millorar-ne la precisió. Això pot implicar afegir variables addicionals que no s'havien considerat inicialment o ampliar el dataset per capturar millor la complexitat del problema.