




Feature Engineering





Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
4. Integrar dades.
5. **Formatar dades (també conegut com a “feature engineering”).**



Preparació de les dades

1. Seleccionar dades.
2. Netejar dades.
3. Construir dades.
4. Integrar dades.
5. Formatar dades (també conegut com a “feature engineering”).
 - **Alguns algorismes de ML ho necessiten i d'altres no.**



Feature engineering

- Imputació de nuls (pels models que no volen nuls).
 - Substituir per mitjana, mediana, moda.
 - Mitjana si volem que valors més extrems tinguin un impacte.
 - Mediana si preferim que valors extrems no afectin.
 - Moda per agafar la categoria més freqüent en variables qualitatives.
 - Substituir per una constant: 0, -1, o qualsevol valor que tingui sentit en les nostres dades.
 - Això seria com crear una categoria especial pels nuls.



Feature engineering

- Codificar característiques categòriques:
 - **Codificació ordinal (ordinal encoding):**
 - Assignar a cada categoria un valor enter únic.
 - Útil quan les categories tenen algun ordre.



Codificació ordinal

SAFETY-LEVEL (TEXT)	SAFETY-LEVEL (NUMERICAL)
None	0
Low	1
Medium	2
High	3
Very-High	4



Feature engineering

- Codificar característiques categòriques:
 - **Codificació ordinal (ordinal encoding):**
 - Assignar a cada categoria un valor enter únic.
 - Útil quan les categories tenen algun ordre.
 - **Codificació one-hot (one-hot encoding):**
 - Crear columnes binàries per a cada categoria.
 - Útil quan les categories no tenen cap ordre específic.
 - Pot ser problemàtic quan hi ha moltes categories (creem moltes columnes).
 - Després d'aplicar one-hot encoding s'elimina la columna original.



One-hot encoding

id	color
1	red
2	blue
3	green
4	blue

One Hot Encoding

id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0



One-hot encoding

- Applicant one-hot a una variable de N categories, en resulten N columnes binàries.
- Realment, només en necessitem N-1 per considerar totes les categories.
- Per exemple:
 - Columna payment_method: “cash” o “card”.
 - Després d’aplicar one-hot encoding, tindríem 2 noves columnes: *is_cash*, *is_card*
 - La seva correlació és de -1... si *is_cash*=0 és equivalent a *is_card*=1 i viceversa.
 - Només en necessitem una de les dues.
 - Una cosa similar passaria si tinguéssim 3 categories, amb 2 variables ja ho codifiquem.




Feature engineering

- **Agrupació (o discretització):**
 - Converteix valors numèrics continus en intervals o compartiments discrets.
 - Avantatges:
 - Redueix l'efecte de les petites fluctuacions,.
 - Converteix les dades esbiaixades en intervals equilibrats i simplifica la interpretació/visualització.
 - Contres: Perd detalls.
 - No t'hi preocupis, excepte si realment necessites simplificar per un motiu rellevant.

Data binning

AGE	AGE_bins
10	[10,16]
15	[10,16]
16	[10,16]
18	[17,30]
20	[17,30]
30	[17,30]
35	[31,48]
42	[31,48]
48	[31,48]
50	[49,55]
52	[49,55]
55	[49,55]



AGE_LABEL
0
0
0
1
1
1
2
2
2
3
3
3



Feature engineering

- Preprocessament de dades:
 - Imputació de nuls.
 - Codificar característiques categòriques:
 - Codificació ordinal.
 - Codificació one-hot.
 - Binning.



Feature engineering

- Preprocessament de dades:
 - Imputació de nuls. → **Sklearn: SimpleImputer**
 - Codificar característiques categòriques:
 - Codificació ordinal. → **Sklearn: OrdinalEncoder**
 - Codificació one-hot. → **Sklearn: OneHotEncoder**
 - Binning. → **Sklearn: KBinsDiscretizer**



Feature engineering

- Recomanació pel curs: fer tot aquest procés en el mateix notebook que farem ML.
 - Això és per evitar *data leakage* (ho veurem més endavant).