

Feature Scaling

Feature Scaling

- El fet que les features puguin tenir escales diferents afecta alguns algorismes de ML.
 - Les escales més grans tenen una influència més gran sobre les distàncies.
- La LR es pot veure afectada per les escales de les features.
 - Amb features escalades pot trobar l'òptim més ràpidament.
 - Sense features escalades no podem inferir quines són més importants (a partir del valor del coeficient).

Feature Scaling

- Amb el feature scaling transformem les features perquè totes tinguin escales similars.
- Tècniques típiques d'scaling:
 - Standardization (`sklearn.preprocessing.StandardScaler`).
 - Min-Max (`sklearn.preprocessing.MinMaxScaler`).
 - Robust (`sklearn.preprocessing.RobustScaler`).
- Podem aplicar scalings abans d'entrenar un model amb `sklearn.pipeline.Pipeline`.

Standard Scaler

- Fórmula: $X_{scaled} = \frac{X - \mu}{\sigma}$
 - X = valors originals.
 - μ = mitjana de la feature.
 - σ = desviació estàndard de la feature.
- Centra les dades al voltant de zero amb una desviació estàndard d'un.
- Bo per a dades distribuïdes normalment.
- Sensible als outliers, que poden afectar significativament la mitjana i la desviació estàndard, provocant un scaling esbiaixat.

Min-Max Scaler

- $X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$
 - X = valors originals.
 - X_{min} = valor mínim de la feature.
 - X_{max} = valor màxim de la feature.
- Escala les dades dins d'un rang entre [0, 1].
- Millor per a dades acotades.
- Sensible als outliers grans, que poden comprimir el rang dels valors no outliers i potencialment esbiaixar els resultats.

Robust Scaler

- Fórmula: $X_{scaled} = \frac{X - Q_2}{Q_3 - Q_1}$
 - X = valors originals.
 - Q_2 = mediana de la feature (percentil 50).
 - Q_1 = primer quartil (percentil 25).
 - Q_3 = tercer quartil (percentil 75).
- Escala les dades a partir de la mediana i el rang interquartílic, fet que el fa robust als outliers.
- Menys efectiu per a dades distribuïdes normalment en comparació amb el Standard Scaler.

Scaling Requirement

Els algorismes de ML supervisats més coneguts que requereixen feature scaling:

- LR (recomanable)
- Lasso / Ridge / ElasticNet
- kNN
- SVM
- Neural Networks

Exemple amb Sklearn

```
In [ ]: from sklearn.linear_model import LinearRegression
        from sklearn.pipeline import Pipeline
        from sklearn.preprocessing import MinMaxScaler
```

```
In [ ]: lr_pipeline = Pipeline([
        ('preprocessor', preprocessor),
        ('scaler', MinMaxScaler()),
        ('model', LinearRegression(n_jobs=-1)),
    ])
    lr_pipeline.fit(X_train, y_train)

    y_pred_train = lr_pipeline.predict(X_train)
    y_pred_test = lr_pipeline.predict(X_test)
```