




Mètodes Lineals





Loss vs Mètrica

- Funció de loss:
 - També coneguda com a funció de cost.
 - El que un algoritme pretén minimitzar durant el procés d'entrenament.
- Mètrica:
 - Mesura utilitzada per jutjar el rendiment del teu model.



Regressió lineal

- Troba l'equació d'un hiperplà adequat per predir:

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + \cdots + w_nx_n$$

- Minimitza la funció de loss:

$$J(w) = MSE(w) = \frac{1}{m} \sum_{i=1}^m (\hat{y} - y)^2$$



Regularització

- Pretén evitar l'overfitting penalitzant la complexitat del model.
- Afegeix una penalització a la funció de pèrdua utilitzada per entrenar el model.
- Desanima els models complexos amb coeficients massa grans.
- Models lineals típics amb regularització:
 - Lasso
 - Ridge
 - ElasticNet



Lasso

- Regularització L1.
- Potencia els coeficients de les característiques menys importants fins a **zero** exactament.
- Bo en entorns d'alta dimensionalitat (nombre de característiques > nombre d'observacions).
- Minimitza la funció de cost:


$$J(w) = \text{MSE}(w) + \alpha \sum_{i=1}^n |w_i|$$



Ridge

- Regularització L2.
- Redueix els coeficients cap a zero sense arribar-hi.
- Computacionalment eficient.
- Pot gestionar altes correlacions entre característiques (multicolinealitat).
- Minimitza la funció de cost:

$$J(w) = \text{MSE}(w) + \alpha \frac{1}{2} \sum_{i=1}^n w_i^2$$





ElasticNet

- Regularitzacions L1 i L2.
- Pot reduir coeficients com Lasso.
- Pot gestionar la multicolinealitat com Ridge.
- Minimitza la funció de cost:
 - α : Penalització aplicada als coeficients.
 - r : Controla el pes entre la penalització L1 (Lasso) i la L2 (Ridge).

$$J(w) = \text{MSE}(w) + r\alpha \sum_{i=1}^n |w_i| + \frac{1-r}{2}\alpha \sum_{i=1}^n w_i^2$$