



Tree-Based Methods




Decision Tree: Dataset



m ²	Tennis	Sale Price
50	0	130k
65	0	250k
25	0	70K
850	1	1M
55	0	150k
300	0	300k
430	0	400k

Decision Tree (DT)



Building a Decision Tree



- Itera sobre cada característica X_i
 - Itera sobre tots els possibles valors V_{ij} d'aquesta característica:
 - Divideix les dades basant-te en el llindar V_{ij} (menors que V_{ij} i majors que V_{ij}).
 - Cadascuna de les dues particions prediu la mitjana dels seus elements.
 - Calcula la mètrica (p. ex., MSE) per a les particions $\rightarrow \text{MSE}_L, \text{MSE}_R$
 - Calcula la mètrica final, que es $\text{MSE}_{\text{total}}$ compón de les altres dues.
- Utilitza la partició que obtingui un $\text{MSE}_{\text{total}}$ més baix.
- Calcula els nodes esquerre i dret de la mateixa manera utilitzant les dades filtrades.

Decision Tree: Dataset



	m ²	Tennis	Sale Price
	50	0	130k
	65	0	250k
	25	0	70K
	850	1	1M
	55	0	150k
	290	0	300k
	430	0	400k

Separa i calcula

MSE_{total}

Decision Tree: Dataset



	m ²	Tennis	Sale Price
	50	0	130k
	65	0	250k
	25	0	70K
	850	1	1M
	55	0	150k
	290	0	300k
	430	0	400k

Separa i calcula

MSE_{total}

Decision Tree: Dataset



	m²	Tennis	Sale Price
	50	0	130k
	65	0	250k
	25	0	70K
	850	1	1M
	55	0	150k
	290	0	300k
	430	0	400k

Separa i calcula

MSE_{total}

Decision Tree: Dataset



	m²	Tennis	Sale Price
	50	0	130k
	65	0	250k
	25	0	70K
	850	1	1M
	etc.	0	150k
	290	0	300k
	430	0	400k

Separa i calcula

MSE_{total}

Decision Tree: Dataset



m ²	Tennis	Sale Price
50	0	130k
65	0	250k
25	0	70K
850	1	1M
55	0	150k
290	0	300k
430	0	400k


- Mateix proces per cada valor de Tennis.
- Separa les dades amb el millor MSE_{total}
- Es repeteix el mateix procés per cada subarbre.




Decision Tree: MSE_total

$$\text{MSE}_{\text{total}} = \frac{\text{size}(\text{Left})}{\text{size}(\text{Left}) + \text{size}(\text{Right})} \times \text{MSE}_L + \frac{\text{size}(\text{Right})}{\text{size}(\text{Left}) + \text{size}(\text{Right})} \times \text{MSE}_R$$

Decision Tree (DT)



Predicció DT (m² and € only)





DT: Hyperparamètres Importants

- Criterion (metric): squared error, absolute error, etc.
- Max. tree depth.
- Min. samples for splitting.
- Min. samples per leaf.
- Max. leaf nodes.



Ensemble

- Combinar diferents models.
- L'ensemble dona millor predicció que cap dels models individualment.
- Tècniques d'ensemble comuns:
 - Bagging (Bootstrap Aggregating)
 - Boosting
 - Stacking




Bagging


- Mètode d'ensemble que combina els resultats de models independents.
- Cada model s'entrena en un subset aleatori de les dades.
- La predicció final serà la mitjana de la predicció de tots els models.
- Avantatges:
 - Redueix l'overfitting.
 - Els models es poden entrenar en paral·lel.
- Model de bagging més famós: Random Forest (RF)
 - Bagging de Decision Trees.

Random Forest (RF)

- Entrena N arbres amb N submostres aleatòries de les dades.
- Predicció = Mitjana de tots els arbres.



Predicció RF (m² and € only)





RF: Hyperparamètres Importants

Same
as DT


- Num. estimators.
- Criterion (metric): squared error, absolute error, etc.
- Max. tree depth.
- Min. samples for splitting.
- Min. samples per leaf.
- Max. features.
- Max. samples.



Boosting

- Mètode d'ensemble que construeix models seqüencialment.
- Primer entrenem un model inicial.
- Cada model seqüencial corregeix els errors del model anterior.
- La predicció final és la combinació de les prediccions de cada model.
- Model de boosting més famós: Gradient Boosted Decision Trees (GBDT)
 - Boosting of Decision Trees.

Gradient Boosted Decision Trees (GBDT)



GBDT: Dataset



X



m²	Tennis	Sale Price (y)
50	0	130k
65	0	250k
25	0	70K
850	1	1M
55	0	150
300	0	300k
430	0	400k


1st prediction:
mean of the
target

[illegible]

GBDT: Dataset

X			1st residuals	
m ²	Tennis	Sale Price (y)	$\bar{y}_1 = F_0$	$r_1 = y - \bar{y}_1$
50	0	130k	329k	199k
65	0	250k	329k	79k
25	0	70K	329k	259k
850	1	1M	329k	-671k
55	0	150	329k	179k
300	0	300k	329k	29k
430	0	400k	329k	-71k

GBDT: Dataset




m ²	Tennis	Sale Price (y)
50	0	130k
65	0	250k
25	0	70K
850	1	1M
55	0	150
300	0	300k
430	0	400k

Train tree with X and $r_1 \rightarrow h_1(X, r_1)$



$\bar{y}_1 = F_0$	$r_1 = y - \bar{y}_1$
329k	199k
329k	79k
329k	259k
329k	-671k
329k	179k
329k	29k
329k	-71k

GBDT: Dataset



m ²	Tennis	Sale Price (y)
50	0	130k
65	0	250k
25	0	70K
850	1	1M
55	0	150
300	0	300k
430	0	400k

New prediction = $y_2 = F_0 + h_1(X, r_1)$

$\bar{y}_1 = F_0$	$r_1 = y - \bar{y}_1$
329k	199k
329k	79k
329k	259k
329k	-671k
329k	179k
329k	29k
329k	-71k

GBDT: Dataset



X



m ²	Tennis	Sale Price (y)
50	0	130k
65	0	250k
25	0	70K
850	1	1M
55	0	150
300	0	300k
430	0	400k

$\bar{y}_1 = F_0$	$r_1 = y - \bar{y}_1$
329k	199k
329k	79k
329k	259k
329k	-671k
329k	179k
329k	29k
329k	-71k

etc. for the
desired number
of trees.

GBDT: Equació de Predicció

$$\hat{F}_M(X) = \hat{y} = F_0(X) + \alpha \underbrace{\sum_{m=1}^M h_m(X, r_m)}$$

Final prediction

Initial prediction (e.g., the mean of the target or a simple DT)

Learning rate

Aggregates the contributions of all M trees



GBDT: Hyperparamètres Importants

Same
as DT

- Num. estimators.
- Learning rate.
- Criterion (metric): squared error, absolute error, etc.
- Max. tree depth.
- Min. samples for splitting.
- Min. samples per leaf.
- Max. features.